


Обучение моделей для анализа тональности русскоязычных текстов


Фёдор Грозовский

Исследовательский (первичный) анализ данных




- **Две конфигурации обучающих датасетов:** вариант **А** – все источники (1,37 млн наблюдений после дедупликации с очень сильным дисбалансом классов в сторону позитивного), вариант **В** – без rating-меток (282 тыс. наблюдений с доминацией distant-типа без нейтрального класса)
- Для оценки точности в качестве основной метрики используется **macro-F1**, которая не дискриминирует менее встречаемые классы в выборке (в отличие от weighted-F1 или Accuracy)

Исследовательский (первичный) анализ данных



Исследовательский (первичный) анализ данных


UMAP по тональности



UMAP по домену




НDBSCAN-кластеризация (22 кластера)




Использованные модели и стратегии обучения

- Возьмем несколько типов решений и обучим их на датасетах А и В:
 - наивный бейзлайн – TF-IDF и линейная модель (LinearSVC)
 - продвинутый бейзлайн – USER-bge-m3-эмбединги с линейной и нелинейной моделями (логистическая регрессия и CatBoost) с подбором гиперпараметров, а также CatBoost с сырыми текстами и дополнительными простейшими текстовыми признаками с подбором гиперпараметров
 - файн-тюнинг языковой модели с подбором гиперпараметров
- Кандидаты для файн-тюнинга отобраны по метрикам качества на RuMTEB (модели до 500 млн параметров и строго $\geq 90\%$ обучающих данных НЕ из бенчмарка):
 - deepvk/USER-bge-m3
 - deepvk/USER2-base
 - ai-forever/ru-en-RoSBERTa
 - sergeyzh/rubert-mini-frida
 - ~~google/embedding-gemma-300m~~ (несовместима с архитектурой доступных мне GPU)
- Сетка гиперпараметров (128 итераций случайного поиска по датасету А): сам энкодер, размер батча, learning rate и доля warmup, количество эпох, максимальная длина входного текста в токенах, коэффициент затухания весов

Результаты обучения моделей (оценка точности in-domain)




Выборка для ООВ-оценки точности



- Датасет подготовлен мною в рамках выполнения курсовой работы; **разметка осуществлялась по правилам аннотирования RuSentiment**
- Для валидации использованных в исследовании моделей создана стратифицированная выборка из **1 067 комментариев**
- Выборка репрезентирует генеральную совокупность из более чем миллиона **эмоционально окрашенных текстов из соцсетей** по показателям пола, города и аудитории автора комментария, дате публикации, длине, лайкам, аудитории блога и платформе («Одноклассники» или Telegram)

ООВ-оценка точности



ru-en-RoSBERTa fine-tuned (B)	0.76	0.68	0.87
cardiff-xlmr	0.79	0.65	0.82
geracl-user2	0.84	0.55	0.78
ru-en-RoSBERTa fine-tuned (A)	0.73	0.62	0.79
CatBoost(emb) (A)	0.72	0.58	0.77
seara-rubert-base	0.65	0.62	0.80
seara-rubert-tiny2	0.62	0.56	0.78
Emb+LogReg(tuned)	0.77	0.46	0.71
cointegrated-tiny	0.69	0.52	0.73
blanchefort-rubert	0.72	0.50	0.71
mdeberta-xnli-2mil7	0.60	0.50	0.77
CatBoost(emb) (B)	0.63	0.56	0.68
mdeberta-mnli-xnli	0.71	0.41	0.72
tabularisai-distil	0.66	0.45	0.69
TFIDF+LinSVC	0.69	0.34	0.69
clapAI-roberta-large	0.83	0.14	0.73
CatBoost(text+feats) (A)	0.50	0.50	0.69
clapAI-modernbert-bs	0.70	0.20	0.68
clapAI-modernbert-lg	0.73	0.16	0.69
CatBoost(text+feats) (B)	0.15	0.48	0.61

negative neutral positive

F1

Выводы

ours: ru-en-RoSBERTa fine-tuned (B)

ИСТИННО	negative	0.65	0.32	0.03
	neutral	0.06	0.85	0.10
	positive	0.04	0.10	0.86
		negative	neutral предсказано	positive

external: cardiff-xlmr

ИСТИННО	negative	0.75	0.14	0.11
	neutral	0.23	0.63	0.15
	positive	0.04	0.06	0.90
		negative	neutral предсказано	positive

zero-shot: geracl-user2

ИСТИННО	negative	0.84	0.06	0.09
	neutral	0.23	0.43	0.34
	positive	0.05	0.03	0.92
		negative	neutral предсказано	positive

- **Дообученный на датасете В** (без наиболее шумных меток тональности) энкодер **ru-en-RoSBERTa** отлично распознает истинный позитивный и нейтральный класс, однако **существенную часть негативных текстов по ручной разметке относит к нейтральному классу** (поскольку последний по-разному определяется в разных источниках данных и представлен в датасете В заметно меньше других меток)
- Тем не менее итоговая модель является **лучшей как при оценке качества in-domain (macro-F1 $\approx 0,9$), так и на независимом ООВ-датасете (macro-F1 $\approx 0,77$); по ROC-AUC (macro-ovr): наша ru-en-RoSBERTa (0,920) > cardiffnlp/twitter-xlm-roberta-base-sentiment $\approx$ deepvk/GeRaCl-USER2-base $\approx$ seara/rubert-base-cased-russian-sentiment (0,898)**

Обучение моделей для анализа тональности русскоязычных текстов

Фёдор Грозовский